

Univerzitet u Novom Sadu
Fakultet tehničkih nauka

**Automatsko generisanje pitanja za proveru znanja po
SOLO taksonomiji primenom velikih jezičkih modela**

master rad

Autor: Uroš Petrašković
Mentor: prof. dr Goran Savić

Novi Sad, 2026.

Abstrakt

Ručno sastavljanje kvalitetnih pitanja za proveru znanja je posao koji oduzima dosta vremena i traži od nastavnika dobro poznavanje gradiva i pravila za pisanje pitanja. Posebno je teško napraviti pitanja koja ciljaju različite kognitivne nivoe. U ovom radu je opisan sistem koji taj posao automatizuje. Sistem iz nastavnog materijala u PDF formatu izdvaja strukturu kursa, gradi ontologiju pojmova i na osnovu nje velikim jezičkim modelom generiše pitanja višestrukog izbora raspoređena po SOLO taksonomiji, od *unistructural* do *extended abstract* nivoa. Težište rada je na sloju za kontrolu kvaliteta. Pošto jezički model sam po sebi pravi dosta grešaka, oko generatora je izgrađen skup provera zasnovanih na pedagoškoj literaturi, koja meri usklađenost pitanja sa zadatim SOLO nivoom, pokrivenost gradiva, tačnost odgovora, kvalitet distraktora, dvosmislenost i čitljivost. Kvalitet sistema je izmeren na slučaju kursa Operativni sistemi, a posebno je analiziran prelazak sa lokalnog modela na model dostupan preko servisa u *cloud*-u, koji je doneo izrazito poboljšanje. Sistem je dodatno proveren i na referentnom skupu EduQG, koji sadrži pitanja koja su pisali stručnjaci.

Ključne reči: automatsko generisanje pitanja, SOLO taksonomija, ontologija, veliki jezički modeli, kvalitet multiple choice pitanja.

1. Uvod

Obrazovanje je oduvek bilo jedan od temelja društva, a kako tehnologija postaje sve prisutnija u svakodnevnom životu, raste i potreba za alatima koji olakšavaju rad nastavnika i učenje studenata. Jedan od poslova koji nastavnicima oduzima dosta vremena jeste sastavljanje pitanja za proveru znanja. Da bi jedno pitanje bilo dobro, ono mora da bude tačno, jasno postavljeno, da pokriva važan deo gradiva i da ima uverljive netačne odgovore tj. distraktore, a uz sve to treba da gađa određeni kognitivni nivo tj. nivo razumevanja. Pisanje takvih pitanja je naporno, pa se u praksi često dešava da provere znanja ostanu na nivou pukog prepoznavanja činjenica, dok dublje razumevanje ostane neprovereno.

Ovaj rad se bavi tim problemom kroz sistem koji nastavni materijal, konkretno predavanja u PDF formatu, pretvara u pitanja za proveru znanja. Za razliku od opštih generatora pitanja, ovaj sistem pitanja razvrstava po SOLO taksonomiji [1] (*Structure of Observed Learning Outcomes*). SOLO taksonomija opisuje kako razumevanje neke teme postepeno raste u složenosti i omogućava da se pitanja prave na različitim kognitivnim nivoima, od onih koja proveravaju jednu činjenicu do onih koja traže primenu naučenog u novom kontekstu. Na taj način se otvara mogućnost da se provere prilagode tome koliko duboko student vlada gradivom.

Da bi generisanje bilo vezano za samo gradivo, a ne za opšte znanje modela, sistem prvo iz materijala izdvaja strukturu kursa. Ta struktura je hijerarhijska: kurs sadrži lekcije, lekcije sadrže sekcije, a sekcije sadrže pojedinačne *learning* objekte. Veze između *learning* objekata se čuvaju u obliku ontologije [2], koja formalno opisuje kako su delovi gradiva povezani. Ontologija kasnije služi i kao pomoć pri kreiranju pitanja viših nivoa, gde pitanje može da testira određenu vezu između pojmova, a ne neku proizvoljnu vezu koju bi model sam izmislio.

Početna verzija ovog sistema je opisana u kraćem konferencijskom radu, gde je kvalitet pitanja procenjen kvalitativno, pregledom po jednog primera za svaki SOLO nivo. Taj rad je pokazao osnovnu ideju, ali je ostavio otvoreno pitanje kako kvalitet izmeriti na sistematičan način i kako ga poboljšati. Master rad nastavlja tu priču na dva načina. Prvo, oko generatora je izgrađen sloj za kontrolu kvaliteta, sastavljen od dvanaest provera koje

su zasnovane na literaturi iz oblasti pisanja test pitanja i psihometrije, kvalitet je izmeren brojkama, po lekcijama i zbirno, i to pre i posle prelaska na jači jezički model. Drugo, sistem je proveren i na spoljnom referentnom skupu pitanja koja su pisali stručnjaci, time vidimo kako naš sistem evaluira pitanja koja su provereno dobro sastavljena da bi proverili koliko dobro rade naše metrike za evaluaciju.

Procena kvaliteta je organizovana oko četiri istraživačka pitanja:

- IP1: Da li generisana pitanja zaista odgovaraju SOLO nivou koji im je dodeljen?
- IP2: Da li su distraktori, odnosno netačni odgovori, uverljivi, međusobno različiti i jasno netačni, a ne parafraze tačnog odgovora?
- IP3: Koliko dobro generisana pitanja pokrivaju nastavni materijal?
- IP4: Da li su pitanja tačna, korektno postavljena i bez halucinacija, odnosno da li je tačan odgovor zaista potkrepljen materijalom?

Svako od ovih pitanja je u radu povezano sa konkretnom merom, pa se na njih ne odgovara utiskom, nego brojem. U nastavku se prvo daje pregled srodnih istraživanja i pokazuje koji je deo svakog rada primenjen u ovom rešenju, zatim se opisuje sam sistem i njegova implementacija, pa se iznose izmereni rezultati, opisuje prototip aplikacije i na kraju izvode zaključci.

2. Srodna istraživanja

Oblast automatskog generisanja pitanja ima dugu istoriju, od ranih sistema zasnovanih na pravilima do današnjih pristupa koji se oslanjaju na velike jezičke modele. Jedan od začetnika oblasti je rad Mitkova (2003) [3], koji je koristio pravila obrade prirodnog jezika da obaveštajne rečenice pretvori u pitanja. Takav pristup je dobro radio za jednostavne činjenice, na primer rečenicu o tome gde se odvija fotosinteza je pretvarao u pitanje gde se fotosinteza odvija, ali se mučio sa složenijim gradivom i često je davao gramatički nezgrapna pitanja. Kasneci i saradnici (2023) [4] dali su pregled primene jezičkih modela poput ChatGPT-a u obrazovanju i ukazali i na potencijal i na rizike, pre svega na pitanja tačnosti, pristrasnosti i potrebe za nadzorom nastavnika. Lister i saradnici (2006) [5] pokazali su kako se SOLO taksonomija može primeniti za klasifikaciju programerskih pitanja, od *unistructural*, kao što je pitanje šta jedna promenljiva čuva, do *extended abstract*, kao što je zahtev da se osmisli program koji rešava složen problem, i upozorili da se provere previše oslanjaju na niže nivoe znanja, a zapostavljaju više. Liang i saradnici (2018) [6] bavili su se generisanjem distraktora pristupom rangiranja, gde se napravi mnogo kandidata pa se biraju oni najuverljiviji, uz zapažanje da dobar distraktor mora biti blizak tačnom odgovoru po značenju, ali pažljivim čitanjem jasno netačan, npr. ako je tačan odgovor mitohondrija, dobri distraktori su ribozomi ili jedro, a ne nepovezani pojmovi.

Sistem opisan u ovom radu nadovezuje se na ta istraživanja, ali ide korak dalje tako što oko generatora postavlja sloj proveru. U nastavku se navode radovi koji su konkretno primenjeni, uz objašnjenje gde su oni primenjeni u našem rešenju.

2.1. Generisanje pitanja i navođenje modela

Polazna tačka za generisanje pitanja je rad Scaria i saradnika (2024) [7], koji se bavi generisanjem pitanja po Blumovoj taksonomiji uz pomoć jezičkih modela. Iako taj rad koristi Blumovu, a ne SOLO taksonomiju, iz njega su preuzeti vredni zaključci o tome kako oblikovati prompt. Prvo, prompt počinje uputstvom u kojem se modelu zadaje uloga stručnjaka za sastavljanje proveru znanja, jer takvo zadavanje uloge primetno poboljšava rezultat. Drugo, traženi kognitivni nivo se opisuje sa svega jednom ili dve rečenice, da definicija bude jasna a ne preopširna. Treće, modelu se daje primer dobrog pitanja, ali ne

previše primera; u tom radu se pokazalo da strategija sa pet npr. primera radi lošije od strategije sa jednim, pa je u ovom sistemu zadržan samo jedan primer. Četvrto, koristi se takozvana lestvica za razmišljanje (*chain of thought*), gde se od modela traži da razmišlja korak po korak pre nego što da konačan odgovor. Bez toga model često sve odradi u jednom potezu, bez provere pojedinačnih koraka, što vodi do haotičnih pitanja i izmišljenih pojmova. Peto, uz svako pitanje se čuva i doslovan citat iz izvornog materijala koji opravdava tačan odgovor, ako takav citat ne postoji, to je znak da je odgovor verovatno izmišljen.

Lestvica za razmišljanje detaljnije je obrađena u radu Wei i saradnika (2022) [8], koji je u celini posvećen tehnici *chain-of-thought* navođenja. To je zapravo ista ideja kao peta tačka prethodnog rada, samo razrađena. Pravljenje pitanja samo jednim pozivom modela nema dovoljno strukture, rezultati dosta variraju i ima previše grešaka. Ako se posao razbije na korake i model se drži preciznih međukoraka, rezultati su znatno bolji, naročito na zadacima koji zahtevaju zaključivanje. U ovom sistemu se taj princip koristi i pri generisanju i pri kasnijoj proveru pitanja.

Pitanje koliko primera dati i kakvi treba da budu povezano je sa teorijom kognitivnog opterećenja, koju su postavili Sweller i Cooper (1985) [9]. Oni su pokazali da rešeni primeri znatno pomažu učenju, što se prenosi i na navođenje modela. Iz tog razloga se u prompt ubacuje primer dobrog pitanja, ali je važan jedan detalj, primer nije iz oblasti koja se trenutno obrađuje. Drugim rečima, ako se generišu pitanja iz operativnih sistema, primer u promptu je iz sasvim druge teme. Tako model preuzima samo formu dobrog pitanja, a ne i temu. U ovom sistemu je za primer uzeta fotosinteza, koja nema nikakve veze sa gradivom kurseva, pa nema opasnosti da model prepíše sadržaj umesto strukture.

2.2. Borba protiv halucinacija

Veliki problem kod velikih jezičkih modela je halucinacija, odnosno izmišljanje sadržaja kojeg nema u materijalu. Prvi mehanizam zaštite oslanja se na ideju iz rada Lewis i saradnika (2020) [10] o generisanju uz pomoć pretrage (*retrieval-augmented generation*). U tom pristupu se odgovor vezuje za izvor. U ovom sistemu se to ostvaruje poljem koje se zove *source line*, a to je doslovan citat iz PDF materijala koji opravdava tačan odgovor. Ako se taj citat ne može pronaći u materijalu, to je jak znak da je odgovor

izmišljen. Polje se čuva i prikazuje, pa nastavnik koji pregleda pitanja može da uporedi citat sa odgovorom. Bitno je naglasiti da se ova provera odnosi pre svega na tačan odgovor, jer je najvažnije da baš on ne bude halucinacija.

Source line rešava slučaj kada model izmisli nešto čega nema u materijalu, ali ne rešava suptilniji problem, a to je kada citat postoji, ali je pogrešno protumačen. Za taj slučaj se koristi metoda iz rada Dhuliawala i saradnika (2024) [17] o lancu provere (*chain of verification*). Umesto da se model jednostavno pita da li je odgovor tačan, na šta bi verovatno lažno potvrdio da jeste, postupak ide u četiri koraka. Najpre se uzme pitanje i tačan odgovor. Zatim se isplaniraju dva do tri kratka pomoćna pitanja čiji odgovori, zajedno gledani, potvrđuju ili obaraju tačan odgovor. Potom se na svako pomoćno pitanje odgovara nezavisno, koristeći samo izvorni materijal. Na kraju se donosi sud da li je tačan odgovor potvrđen, neodređen ili oboren. Pitanja koja su neodređena ili oborena se označavaju za ljudski pregled.

2.3. Generisanje distraktora

Način generisanja distraktora za najsloženija pitanja preuzet je iz rada Bitew i saradnika (2023) [11] o generisanju distraktora prediktivnim navođenjem. Pošto su *extended abstract* najteža, kod njih se distraktori prave u dva prolaza. U prvom prolazu model osmisli i zapamti tačan odgovor, objašnjenje, citat iz materijala i sam tekst pitanja. Drugi prolaz služi isključivo za pravljenje tri distraktora, gde se model trudi da ih napiše kao stvarne zablude i da svaki sledi drugačiju strategiju. Veoma važan zaključak iz tog rada je da se pazi da distraktori ne budu slični i da dva distraktora ne predstavljaju isti pogrešan koncept samo drugačije sročeni. Pošto model ima ograničenu pažnju, kvalitet distraktora je primetno bolji kada se oni ne prave u isto vreme kada i sve ostalo, nego se za njih napravi poseban poziv. U pomenutom radu se navodi da je za *extended abstract* pitanja oko 53% distraktora spremno za upotrebu, što govori koliko je taj nivo težak.

Da bi posao bio sistematičan, za svaki SOLO nivo su definisani tipovi distraktora, čime generisanje postaje gotovo šablonsko:

- Unistructural: VARIANT_OF_CORRECT, NEAR_SYNONYM,
COMMON_MISCONCEPTION.

- Multistructural: LIST_WITH_ONE_WRONG_ITEM, LIST_MISSING_ONE_ITEM, RELATED_BUT_OUT_OF_SCOPE.
- Relational: REVERSED_CAUSE_EFFECT, CORRELATION_AS_CAUSATION, DIFFERENT_REAL_RELATIONSHIP.
- Extended abstract: APPLIES_WRONG_PRINCIPLE, RIGHT_PRINCIPLE_WRONG_DOMAIN, OVER_GENERALIZATION.

Drugi važan deo ovog rada je upotreba embeddinga, gde se tekst pretvara u vektore, pri čemu sličan tekst ima sličan vektor. Tu se rad naslanja na BERT Score, koji su predložili Zhang i saradnici (2019) [12]. Koristi se mera kosinusne sličnosti, koja govori koliko su dva vektora slična po smeru. Rezultat je broj između minus jedan i jedan, gde jedan znači gotovo isto značenje, oko 0,9 vrlo slično, oko 0,5 blisko ali ipak različito, nula nepovezano, a negativne vrednosti suprotno značenje. U kodu postoje pragovi za najmanju i najveću uverljivost: distraktor čija je sličnost sa tačnim odgovorom veća od 0,92 smatra se parafrazom, a onaj sa sličnošću manjom od 0,40 smatra se previše očigledno netačnim. Ti pragovi nisu proizvoljni, nego su dobijeni kalibracijom. Na isti način se distraktori porede i međusobno, jer je čest problem bio da dva distraktora znače istu stvar; uvođenje embeddinga i pravila iz literature znatno je popravilo tu stranu generisanja.

2.4. Pitanja relacionog nivoa i ontologija

Za generisanje pitanja relacionog nivoa korišćen je rad Chen i Shiu (2025) [15], koji spaja graf znanja i generisanje uz pomoć pretrage radi kontrole težine pitanja. Glavni zaključak je da je neophodno koristiti *anchor* tj. sidro, odnosno tačno zadatu vezu u grafu znanja. Ako se modelu ne kaže kojom se vezom tačno bavi, on počinje da luta i pitanja skreću ka uopštenim poređenjima. Sidro tu opštost sprečava i usmerava model na tačno određeni deo grafa koji je izgrađen iz ontologije. Ako, na primer, postoji veza tipa preduslov, modelu se izričito kaže da mora da testira baš tu vezu, a ne neku drugu koju bi mogao da pretpostavi. U sklopu ovog dela je iznova napisan ceo postupak generisanja ontologije, sa težištem na kvalitetu, pa je rezultat manji broj veza koje su zato znatno pouzdanije. Sve veze se čuvaju i kasnije porede sa tim koliko ih pitanja pokrivaju.

2.5. Pravila za pisanje pitanja i provera kvaliteta

Osnovni skup pravila za pisanje pitanja višestrukog izbora preuzet je iz rada Haladyna, Downing i Rodriguez (2002) [16], koji sadrži čak trideset jedno pravilo, provereno kroz dvadeset sedam empirijskih studija i veliki broj udžbenika. U sistemu se koriste dve grupe pravila: STEM_RULES za tekst pitanja i OPTION_RULES za odgovore. Činjenica da su pravila numerisana ima praktičan značaj, jer ih model tako mnogo bolje prati nego kada su data kao slobodan tekst. Pravila se najpre stavljaju u prompt kao mera prevencije, a zatim se naknadno proverava da li ih se model držao. Neka od pravila su:

- Stem rule 1: pitanje se završava upitnikom ili jasnim imperativom.
- Stem rule 2: tekst je kraći od oko 250 znakova, bez nepotrebnog ukrasa.
- Stem rule 3: izbegavati negaciju, a ako se koristi, istaći je.
- Option rule 1: tačno jedna opcija je tačna.
- Option rule 2: nijedne dve opcije nisu parafraze jedna druge.
- Option rule 3: najduža opcija nije duža od dvostruke najkraće.
- Option rule 4: ne koristiti odgovore tipa svi navedeni ili nijedan navedeni.
- Option rule 5: numeričke opcije idu rastuće ili opadajuće.
- Option rule 6: opcije imaju istu gramatičku strukturu, istu vrstu reči i isti register.

Ovaj rad je posebno pomogao kod distraktora. Ako je tačan odgovor glagol, a distraktori imenice ili obrnuto, to studentu olakšava da pogodi tačan odgovor, na šta se odnosi *option rule 6*. Slično, ako je tačan odgovor osetno duži od distraktora, to je trag, što pokriva *option rule 3*. Rad uvodi i sloj provere kvaliteta i valjanosti pre upotrebe, gde pitanje nakon generisanja prolazi kroz validaciju. Znači za proveru pravila se koriste oba pristupa: prvo u promptu koji radi prevenciju koristi se jezički model, a u drugom prolazu se u većini slučajeva ne koristi model, nego samo mehanizam za pravila proverava da li su pravila ispoštovana.

Posebna pažnja se poklanja pravilu da tekst pitanja mora da nosi glavnu misao, tako da bi onaj ko rešava test trebalo da može da odgovori već iz teksta pitanja, pre nego što uopšte pogleda ponuđene opcije. Ovo pravilo se ne može proveriti na uobičajen način, nego se mora pozvati model. Model pokušava da odgovori na pitanje bez ponuđenih opcija, a zatim se taj odgovor poredi sa tačnim odgovorom da bi se videlo koliko se poklapaju. To

je dodatni prolaz modela koji daje koeficijent poklapanja i znatno produžava vreme obrade, ali se isplati jer otkriva pitanja koja se ne mogu rešiti bez gledanja u opcije.

2.6. Procena težine i klasifikacija nivoa

Za procenu težine pitanja korišćen je pristup iz klasične teorije testova, koju su izložili Crocker i Algina (1986) [18]. Tačan odgovor se sakrije od modela, pa se model pita da reši pitanje, i to se ponovi određeni broj puta da bi se dobila mera koliko dobro pogađa. Uvodi se koeficijent p koji govori koliko je pitanje lako. Ako je $p = 1$, pitanje je trivijalno ili postoji neki trag koji ga odaje, na primer dužina ili gramatička razlika opcija. Ako je p između 0,6 i 0,9, reč je o adekvatnoj težini za model koji rešava. Ako je p manje od 0,5, pitanje je ili loše postavljeno, ili je odgovor pogrešan, isto može biti da se odgovor ne nalazi u materijalu.

Da bi se proverilo da li pitanja zaista pripadaju nivou koji im je dodeljen, koristi se drugi jezički model koji ne zna koji je nivo tražen i koji svako pitanje samostalno klasifikuje. Napomena da u slučaju kada se ne radi lokalno se ne koristi drugi model, već koristi se isti Haiku 4.5. Nakon odluke modela se meri koliko se njegova procena slaže sa zadatim SOLO nivoom. Slaganje se ne meri prostim procentom pogodaka, jer bi to bilo naivno: ako je većina pitanja *unistructural*, pošto su ona najlakša za generisanje, model bi mogao da postigne visok procenat samo tako što uvek tipuje na najčešći nivo. Zato se koristi Koenov koeficijent kapa, predstavljen u radu Cohen (1960) [21], a tumačenje vrednosti prati skalu iz rada Landis i Koch (1977) [20]. Kapa u svoju formulu uračunava slaganje koje bi nastalo i pukim slučajem, pa daje realniju sliku. Vrednost jedan znači savršeno slaganje, vrednost između 0,6 i jedan znači da je generator dobar, nula znači slaganje na nivou slučajnosti, a negativna vrednost znači da je generator gori nego nasumično pogađanje. Uz kapa vrednost se prikazuje i matrica konfuzije, koja pokazuje na kom se nivou koliko greši.

2.7. Pokrivenost gradiva, čitljivost, dvosmislenost i zablude

Za procenu koliko pitanja pokrivaju gradivo oslonac je rad Kurdi i saradnika (2020) [22], sistematski pregled automatskog generisanja pitanja u obrazovne svrhe. Starija verzija sistema merila je pokrivenost brojem stranica i znakova, što ne govori ništa o semantičkoj pokrivenosti. Zato se ovde koristi pokrivenost pojmova, gde je skup pojmova unija

learning objekata i svih njihovih ključnih reči. Taj rad je uveo pokrivenost zasnovanu na grafu znanja i skrenuo pažnju na slabosti merenja preko stranica. U ovom sistemu se za svaki pojam gleda koliko veza ima u ontološkom grafu, pa pojam koji se češće pominje ima veću težinu. Pojam kao što je proces je veoma čest i on povezuje sve ostalo, pa ako ga pitanje pominje, pokrilo je važan deo gradiva, dok reči pojmovi nose manju težinu. Kod višerečnih pojmova reči se filtriraju tako da moraju biti jedna za drugom, jer ako se dve reči nađu u istoj rečenici, to ne mora da znači da je reč o tom pojmu. Na kraju se prikazuju ponderisana i neponderisana pokrivenost, gde ponderisana uzima u obzir koliko je važan pojam koji je pokriven.

Čitljivost pitanja meri se formulama iz radova Flesch (1948) [23] i Kincaid i saradnici (1975) [24]. Te formule koriste prosečan broj reči po rečenici i prosečan broj slogova po reči i procenjuju koji bi školski razred mogao sa razumevanjem da pročita tekst. Cilj je da pitanja nižih kognitivnih nivoa imaju manji zahtev za čitanje, odnosno da budu lakša za čitanje. Ova provera ne koristi poziv modela.

Dvosmislenost se procenjuje na osnovu rada Downing (2005) [25] o posledicama kršenja pravila za pisanje pitanja. Reč je o slučaju kada se nešto sroči tako da može imati dva značenja, pa onaj ko rešava test razume pitanje drugačije nego što je pisac mislio. Ono što je nastavniku odmah jasno može studenta da navede na pogrešan trag ako su pojmovi dvosmisleni. Ovde se koristi model, a prompt izričito traži da model izdvoji alternativna tumačenja, a ne da samo kaže da li je nešto nejasno. Kao i kod većine ovih stvari se dodaje određeni broj poena upozorenja kada se i beleži se razlog, koji korisnik kasnije može da vidi.

Najzad, distraktori se prave po uzoru na rad Sadler (1998) [26], koji pokazuje da se najbolji distraktori dobijaju praćenjem samog materijala, jer u materijalu često već piše šta se obično brka i gde se greši. Umesto da model sam izmišlja zablude, one se vade iz materijala. Koriste se obrasci kao što su česta greška, studenti često misle, za razliku od, ne treba mešati, *a common error, students often think, unlike X, Y is i not to be confused with*. Pronađeni delovi se podele na delove i šalju se modelu, koji procenjuje da li je reč o stvarnoj zabludi ili o lažnom pogotku obrasca.


2.8. Referentni skup za evaluaciju

Za spoljnu proveru sistema korišćen je skup EduQG, koji su predstavili Hadifar i saradnici (2023) [27]. To je skup od 3397 pitanja višestrukog izbora koja su pisali stručnjaci, izvučenih iz dvanaest udžbenika, gde je svako pitanje vezano za izvorni tekst na nivou rečenice. Pošto su ta pitanja pisali stručnjaci, ona služe kao spoljni zlatni standard. Time se ne proverava samo generator, nego i sami merni instrumenti: ako provere previše često označavaju stručnjačka pitanja kao loša, znači da su loše podešene. Ova uloga EduQG skupa detaljnije je opisana u poglavlju o rezultatima.

3. Sistem za kreiranje pitanja po SOLO taksonomiji

3.1. SOLO taksonomija

SOLO taksonomija opisuje kako razumevanje neke teme raste u složenosti i sastoji se od pet nivoa. Na *prestructural* nivou student još nema razumevanje teme i odgovori su uglavnom nebitni ili izostaju. Na *unistructural* nivou razume jedan aspekt. Na *multistructural* razume više aspekata, ali ne vidi kako su povezani. Na *relational* nivou ume da poveže delove u celinu. Na *extended abstract* nivou ume da uopšti i primeni znanje u novim situacijama. Sistem generiše pitanja za četiri viša nivoa, jer prestrukturalni nivo po definiciji ne odgovara nijednom smislenom pitanju. *Unistructural* pitanja se tiču jedne činjenice, *multistructural* više činjenica, *relational* traže povezivanje pojmova, a *extended abstract* traže primenu naučenog u novom kontekstu.



Slika 1. SOLO taksonomija: četiri nivoa koja sistem generiše, poredana po porastu kognitivne složenosti.


3.2. Arhitektura i tok obrade

Sistem je izveden kao veb aplikacija sa troslojnom monolitnom arhitekturom. Korisnički deo je napravljen u tehnologiji React, serverski deo u okviru Flask na jeziku Python, a podaci se čuvaju u bazi SQLite. Pored relacione baze, struktura kursa se čuva i u obliku ontologije, nad kojom se mogu postavljati upiti jezikom SPARQL. Osnovna funkcija sistema je automatsko pravljenje provera znanja po SOLO taksonomiji, kroz tok obrade koji sirov materijal pretvara u struktuirane kvizove.

Tok počinje učitavanjem nastavnog materijala u PDF formatu, nakon čega se tekst šalje modelu na raščlanjivanje. Arhitektura ne zavisi od konkretnog modela, pa se može koristiti i lokalni i model u cloud-u. Model iz sirovog materijala izdvaja strukturu kursa i smešta je u bazu kao hijerarhiju: kurs sadrži lekcije, lekcije sadrže sekcije, a sekcije sadrže *learning* objekte. Kada su nastavni objekti napravljeni, sistem automatski uspostavlja ontološke veze između njih, koje se mogu izvesti i kao OWL datoteka. Zatim sistem prolazi kroz *learning* objekte i veze i generiše pitanja za sva četiri SOLO nivoa, pri čemu se za svaki nivo koristi prompt prilagođen traženoj složenosti. Svako pitanje se čuva zajedno sa opcijama, tačnim odgovorom, objašnjenjem i citatom iz materijala. Na

kraju nastavnik bira teme i broj pitanja po nivou, pa sistem od tog skupa sastavlja proveru.

Tok obrade: od nastavnog materijala do provere znanja



Slika 2. Tok obrade sistema, od nastavnog materijala u PDF formatu do gotove provere znanja.

3.3. Generisanje pitanja po nivoima

Svaki nivo se generiše posebnim promptom. Zajednički delovi svih promptova su uloga stručnjaka za sastavljanje provera, kratak opis traženog nivoa, jedan primer dobrog pitanja iz nepovezane oblasti, lestvica za razmišljanje i pravila za tekst i opcije. *Unistructural* i *multistructural* pitanja se generišu u jednom prolazu. Relational pitanja se vezuju za tačno određenu vezu iz ontologije, koja služi kao sidro, da pitanje ne bi skliznulo u opšte poređenje. *Extended abstract* pitanja se generišu u dva prolaza. U prvom prolazu se generiše tekst pitanja, tačan odgovor, objašnjenje i citat, a u drugom se prave distraktori, svaki po svojoj strategiji. Razlog za dva prolaza je ograničena pažnja modela, kada model istovremeno mora da smisli i scenario i distraktore, kvalitet opada, pa se poseban poziv za distraktore isplati.

3.4. Sloj za kontrolu kvaliteta

Najveća razlika u odnosu na početnu verziju sistema je sloj za kontrolu kvaliteta. On radi na dva načina. Prvi je prevencija, gde se pravila i smernice ugrađuju u sam prompt, gde model pokušava preventivno grešku. Drugi je naknadna provera, gde se već generisano pitanje proverava. Ukupno se koristi dvanaest provera, koje pokrivaju četiri istraživačka pitanja iz uvoda. Tabela u nastavku daje pregled provera, izvora na kojem se zasnivaju i istraživačkog pitanja na koje se odnose.

- IP1: Da li generisana pitanja zaista odgovaraju SOLO nivou koji im je dodeljen?
- IP2: Da li su distraktori, odnosno netačni odgovori, uverljivi, međusobno različiti i jasno netačni, a ne parafraze tačnog odgovora?

- IP3: Koliko dobro generisana pitanja pokrivaju nastavni materijal?
- IP4: Da li su pitanja tačna, korektno postavljena i bez halucinacija, odnosno da li je tačan odgovor zaista potkrepljen materijalom?

Provera	Izvor	Tiče se
Pokrivenost pojmova	Kurdi 2020 [22]	IP3
Haladyna pravila (<i>rule engine</i>)	Haladyna 2002 [16]	IP2, IP4
Klasifikacija SOLO nivoa (kapa)	Cohen 1960 [21], Landis i Koch 1977 [20]	IP1
Lanac provere (CoVe)	Dhuliawala 2024 [17]	IP4
Procena težine (p vrednost)	Crocker i Algina 1986 [18]	IP4
Rešivost iz teksta (<i>stem only</i>)	Haladyna 2002 [16], rule H4	IP4
Indeks podudaranja sa ciljem (IOC)	Rovinelli i Hambleton 1977 [19], Crocker i Algina 1986 [18]	IP1, IP4
Čitljivost (Flesch, Kincaid)	Flesch 1948 [23], Kincaid 1975 [24]	IP4
Dvosmislenost	Downing 2005 [25]	IP4
Gramatička ujednačenost opcija	Haladyna 2002 [16], rule O7	IP2, IP4
Uverljivost distraktora (<i>face validity</i>)	Considine 2005 [13], Tarrant i Ware 2008 [14]	IP2
Vađenje zabluda iz materijala	Sadler 1998 [26]	IP2

Tabela 1. Provere kvaliteta, izvori i istraživačka pitanja na koja se odnose.

Provere koje ne traže poziv modela, kao što su pravila pisanja, pokrivenost pojmova i čitljivost, su brze i deterministične. Provere koje traže model, kao što su klasifikacija nivoa, lanac provere, procena težine, rešivost iz teksta, dvosmislenost, gramatička ujednačenost i uverljivost, su sporije i čine da generisanje i provera traju osetno duže. Da se isti rezultat ne bi računao više puta, skupi rezultati se keširaju, kako pojedinačni pozivi modela, tako i celi izveštaji po lekciji, pa se pri ponovnom otvaranju lekcije rezultati odmah prikazuju.

3.5. Lokalni i globalni model

Pošto sistem ne zavisi od konkretnog modela, isti tok obrade se može pokrenuti i sa lokalnim modelom i sa modelom u *cloud*-u. U prvoj fazi rada korišćen je lokalni model Qwen 2.5 sa 14 milijardi parametara, koji se može pokrenuti na ličnom računaru bez interneta i bez ključeva za pristup. Kasnije je sistem prebačen na model Claude Haiku 4.5, dostupan preko *cloud* servisa. Kao što će biti pokazano u poglavlju o rezultatima, ta promena je donela izrazito poboljšanje, naročito kod provera koje traže zaključivanje. To je i očekivano, jer sloj za kontrolu kvaliteta u velikoj meri zavisi od sposobnosti modela da sudi, a tu lokalni model od četrnaest milijardi parametara nije bio dovoljan.


4. Rezultati

4.1. Opis studije slučaja

Kvalitet sistema je izmeren na kursu Operativni sistemi, uzete tri lekcije: Procesi, Niti i Konkurentnost. Iz tih lekcija je ukupno generisano 246 pitanja, i to 90 za lekciju Procesi, 66 za lekciju Niti i 90 za lekciju Konkurentnost. Po SOLO nivoima, najbrojnija su unistrukturalna pitanja, kojih ima 111, zatim multistrukturalna sa 75, relaciona sa 50 i prošireno apstraktna sa 10. Ovakav raspored je očekivan, jer su niža pitanja lakša za generisanje i ima ih više, što je upravo razlog zašto se slaganje nivoa meri Koenovim koeficijentom, a ne prostim procentom. Prilikom selektovanja opcije za generisanje pitanja na osnovu svih dostupnih materijala se nije generisalo ni jedno extended abstract pitanje za lekciju Konkurentnost, što lako može biti manuelnim selektovanjem te lekcije i generisanjem tog tipa pitanja, ali u ovom slučaju u prvom prolazu nisu pronadjena adekvatna *extended abstract* pitanja za tu oblast.

Lekcija	Broj pitanja	Uni	Multi	Relational	Ext. abstr.
Procesi	90	40	27	18	5
Niti	66	31	18	12	5
Konkurentnost	90	40	30	20	0
Ukupno	246	111	75	50	10

Tabela 2. Pregled studije slučaja i raspodela pitanja po SOLO nivoima.



Slika 3. Raspodela generisanih pitanja po SOLO nivoima i lekcijama.

4.2. Kvalitativna analiza generisanih pitanja po nivoima

Pre brojki, korisno je pogledati po jedan tipičan primer za svaki SOLO nivo i prokomentarisati kvalitet pitanja i njegovih distraktora, kao što je rađeno u početnom radu. Ova analiza je kvalitativna i služi kao dopuna mernim rezultatima koji slede.

Unistruktural nivo

Unistrukturalna pitanja izdvajaju jedan osnovni pojam. Kao primer uzimamo pitanje: Šta je međusobna isključivost u kontekstu konkurentnih procesa? Tačan odgovor je da je to mogućnost procesa da obavi akciju bez negativnog uticaja drugih procesa.

Distraktori su pokazali različit kvalitet. Najjači je tvrdnja da je međusobna isključivost usklađivanje ponašanja procesa sa aktivnošću drugih procesa, jer to zapravo opisuje sinhronizaciju, a brkanje međusobne isključivosti i sinhronizacije je jedna od najčešćih grešaka kod ove teme, pa pogađa studente koji ta dva pojma poistovećuju. Srednje jak je distraktor da je reč o dodeljivanju resursa procesu koji ga trenutno ne koristi, jer dotiče problem komplikovane dodele resursa i uzajamnog blokiranja, pa može da privuče studenta koji povezuje srodnu, ali pogrešnu temu. Najslabiji je distraktor o sprečavanju detekcije grešaka, jer nema jasnu vezu sa pojmom i student ga lako odbacuje.

Multistructural nivo

Multistrukturalna pitanja traže da student barata sa više nezavisnih aspekata, obično kroz nabranje. Kao primer uzimamo pitanje: Navedi tri događaja koji izazivaju prelaz procesa iz stanja Izvršavanja u Spreman. Tačan odgovor su istek kvantuma, pojava spremnijeg procesa višeg prioriteta i dobrovoljno prepuštanje procesora.

Distraktori su dobro osmišljeni jer ne ubacuju nasumične pojmove, nego događaje koji izazivaju druge prelaze, pa zahtevaju da student tačno zna koji događaj vodi u koje stanje. Najteži je distraktor koji navodi istek kvantuma, čekanje na događaj i dobrovoljno prepuštanje, jer su dva od tri tačna, a samo čekanje na događaj zapravo vodi u stanje Blokiran, a ne Spreman, pa ga mogu izabrati i studenti koji solidno poznaju gradivo. Srednje jak je distraktor sa zahtevom za U/I operaciju i čekanjem podataka, jer su to takođe prelazi u Blokiran, ali ih je lakše prepoznati kao pogrešne. Najslabiji je distraktor sa završetkom izvršavanja, jer taj događaj vodi u stanje Izlaz, pa ga student koji zna model stanja brzo eliminiše.

Relational nivo

Relaciona pitanja traže povezivanje pojmova. Kao primer uzimamo pitanje: Kako je nit kao tok izvršavanja povezana sa procesom u kojem se izvršava? Tačan odgovor je da je nit jedan tok izvršavanja unutar procesa, pri čemu jedan proces može sadržati više konkurentnih niti.

Pitanje je relaciono jer ne traži definiciju niti, nego odnos između niti i procesa. Najzanimljiviji distraktor je tvrdnja da je nit nezavisna jedinica raspoređivanja kojom operativni sistem upravlja odvojeno od procesa, jer sadrži pola istine: niti jesu jedinice raspoređivanja, ali ne postoje odvojeno od procesa, nego unutar njega i dele njegove resurse. Takav distraktor pogađa studente koji su zapamtili da se niti raspoređuju, ali nisu razumeli da pripadaju procesu. Distraktor da nit zamenjuje proces kao osnovnu jedinicu izvršavanja preuveličava odnos i meša hijerarhiju pojmova. Najslabiji distraktor svrstava nit u spoljašnji događaj koji menja stanje procesa, što je greška u kategoriji, jer brka nit sa prekidom, pa se lako odbacuje.

Extended Abstract nivo


Prošireno apstraktna pitanja traže uopštavanje i primenu naučenog u novom, složenijem kontekstu. Kao primer uzimamo pitanje: U distribuiranom računarskom okruženju, ako glavni proces stvara više procesa deca na različitim čvorovima, koji mehanizam obezbeđuje da svi procesi deca dobiju ispravne sistemske resurse i da se međusobno ne ometaju? Tačan odgovor je primena protokola međuprocene komunikacije (IPC) za upravljanje dodelom resursa i sinhronizacijom.

Pitanje uspešno uzima pojam upravljanja procesima, koji se obično uči u kontekstu jedne mašine, i traži da se prenese na distribuirano okruženje. Opcija da se svi procesi deca dodele jednom čvoru radi centralizovanog upravljanja dobro cilja zabludu da je centralizacija rešenje, iako ona poništava sam smisao distribucije. Opcija o sinhronizaciji na nivou niti unutar svakog čvora prepoznaje delimičnu istinu, jer rešava samo probleme unutar čvora, a ne širi distribuirani problem. Opcija o povećanju prioriteta roditeljskog procesa nad decom je suviše očigledno netačna, jer povećanje prioriteta logički nema veze sa dodelom resursa ili sprečavanjem ometanja između čvorova, pa se lako eliminiše.


Za razliku od početne verzije sistema, gde je kvalitet izrazito opadao sa porastom SOLO nivoa, izabrani primeri pokazuju da sada i pitanja viših nivoa mogu imati uverljive i dobro ciljane distraktore. Kod sva četiri nivoa distraktori ne ubacuju nasumične pojmove, nego prate stvarne zablude i greške u rezonovanju, sa jasnom razlikom u težini između jačeg i slabijeg distraktora. To ne znači da problema nema, jer se i dalje ponegde javlja distraktor koji je previše očigledno netačan ili previše blizak tačnom odgovoru, što je upravo razlog zašto se u nastavku uvodi merni i korektivni sloj koji takve slučajeve automatski otkriva.

4.3. Prelazak sa lokalnog na globalni model


Najvažniji rezultat je poređenje lokalnog i globalnog modele, ceo pipeline za parsiranje teksta, generisanje ontologija, pitanja i krajnje evaluacije je ovaj put odrađen sa Haiku 4.5 modelom. Sledeće slike prikazuju kontrolne table kvaliteta za sve tri lekcije. Razlika je izrazita kod svih provera koje traže zaključivanje.



Slika 4. Kontrolne table kvaliteta za Lekciju procesi. Gore je lokalni model (Qwen 2.5 14B), Dole je globalni model (Claude Haiku 4.5).



Slika 5. Kontrolne table kvaliteta za Lekciju Niti. Gore je lokalni model (Qwen 2.5 14B), Dole je globalni model (Claude Haiku 4.5).



Slika 6. Kontrolne table kvaliteta za Lekciju Konkurentnost. Gore je lokalni model (Qwen 2.5 14B), Dole je globalni model (Claude Haiku 4.5).

Tabela 3 sažima ključne mere za sve tri lekcije, pre i posle prelaska na globalni model. Vrednosti su zaokružene onako kako ih sistem prikazuje.

Mera	Procesi L	Procesi G	Niti L	Niti G	Konkur. L	Konkur. G
Pokrivenost pojmova	58,3%	54,6%	58,0%	63,9%	41,1%	50,6%
Haladyna prosek	95,3	95,4	96,5	95,4	96,0	95,9
SOLO kapa	0,63	0,78	0,64	0,78	0,27	0,68
CoVe potvrđeno	10%	38,9%	14,3%	59,2%	18,8%	41,1%
Rešivost (mean p)	0,66	0,88	0,71	0,94	0,78	0,91
Rešivost iz teksta	0%	50%	0%	69%	0%	64,2%
IOC indeks	-0,01	0,69	-0,04	0,66	0,02	0,62
Čitljivost (FK)	17,4	19,1	13,5	16,4	16,1	21,3
Dvosmislenost	52,5%	4,4%	48,2%	7%	51,6%	3,2%
Gram.	68,8%	92,2%	67,9%	87,3%	64,1%	90,5%


ujednačenost						
Uverljivost distr.	3,45	3,69	3,37	3,58	3,47	3,51

Tabela 3. Mere kvaliteta po lekcijama, lokalni (L) i globalni (G) model.


Iz tabele se vidi nekoliko jasnih obrazaca. Slaganje sa SOLO nivoom, mereno Koenovim koeficijentom, sa lokalnim modelom je bilo od 0,27 do 0,64, što je u rasponu od slabog do umerenog, dok je sa globalnim modelom poraslo na 0,68 do 0,78, što se tumači kao značajno slaganje. Lanac provere, koji meri koliko je tačnih odgovora zaista potkrepljeno materijalom, sa lokalnim modelom je potvrđivao svega 10 do 18,8 procenata pitanja, a sa globalnim 38,9 do 59,2 procenata. Provera rešivosti iz teksta je sa lokalnim modelom bila na nuli za sve tri lekcije, jer model nije umeo da odgovori na pitanje bez gledanja u opcije, dok je sa globalnim modelom prošla 50 do 69 procenata pitanja. Indeks podudaranja sa ciljem je sa lokalnim modelom bio oko nule ili negativan, što znači da pitanja nisu merila ono što je trebalo, a sa globalnim je porastao na vrednosti oko 0,6 do 0,7, koje se smatraju prihvatljivim. Dvosmislenost je sa lokalnog modela, gde je oko polovine pitanja bilo označeno kao dvosmisleno, pala na svega nekoliko procenata. Gramatička ujednačenost opcija je porasla sa oko dve trećine na preko 87 procenata.

Nasuprot tome, deterministične mere koje ne zavise mnogo od modela ostale su slične. Prosečna ocena po Haladyna pravilima je u oba slučaja blizu 95 od 100, jer ta pravila proverava programski mehanizam, a ne model. Čitljivost i pokrivenost pojmova se razlikuju, ali bez jasnog smera, pošto zavise i od toga kako je izgrađena struktura kursa. Uverljivost distraktora je blago porasla. Iz svega ovoga sledi jasan zaključak: lokalni model od četrnaest milijardi parametara nije bio dovoljan za sloj koji sudi o pitanjima, pa je za pedagoški smislenu proveru bio neophodan jači model. Same provere, kao programski okvir, radile su isto u oba slučaja, ali je kvalitet zavisio od modela.


Naredne tri slike vizuelno sažimaju ovu razliku. Prva daje grupisani prikaz ključnih mera u proseku za tri lekcije, druga isti odnos prikazuje kao radarski profil, a treća kao toplotnu mapu poboljšanja po lekciji i meri.



Slika 7. Ključne mere sloja provera, lokalni naspram globalnog modela (prosek tri lekcije). Kod svih mera viša vrednost je bolja; dvosmislenost je prikazana kao jasnoća, odnosno 100 minus stopa dvosmislenosti.




Slika 8. Radarski profil kvaliteta. Površina globalnog modela obuhvata površinu lokalnog na svim osama.



Slika 9. Toplotna mapa poboljšanja: razlika između globalnog i lokalnog modela, po meri i lekciji. Tamnije polje znači veći porast.

4.4. Poboljšanje lanca provere

Tokom rada tj. tokom provere nad ekspertskim pitanjima iz EduQG dataseta uočeno je da lanac provere često označava pitanja kao neodređena ne zato što su loša, nego zato što mu je dat premali kontekst. U prvobitnoj verziji se tačnost proveravala samo u odnosu na jedan citat iz materijala, što je za mnoga pitanja premalo. Provera je izmenjena tako da koristi širi kontekst, odnosno sam *learning object* uz citat. Posle te izmene, na lekciji Procesi je udeo potvrđenih pitanja porastao sa 38,9 na 54,4 procenta, dakle za petnaest procentnih poena, bez ikakve promene u samim pitanjima. To pokazuje da se deo ranije označenih pitanja nije zaista loš, nego je proveri jednostavno nedostajao kontekst. Ovu promenu ne bismo napravili da nismo uvideli grešku u evaluacionom procesu koju su otkrila pitanja koja su napravili eksperti.



Slika 10. Udeo potvrđenih odgovora po lekciji.

4.5. Spoljna provera na referentnom skupu EduQG

Da bi se proverilo da li su sami merni instrumenti dobro podešeni, sloj provera je pušten i nad pitanjima iz skupa EduQG, koja su pisali stručnjaci. Ideja je jednostavna: ako su provere dobro podešene, one bi trebalo da propuste veliku većinu stručnjačkih pitanja, jer su to po pretpostavci dobra pitanja. Korišćen je uzorak od 149 pitanja iz dvanaest udžbenika, a kao model za sud je korišćen Claude Haiku 4.5, isti kao u produkciji. Tabela 4 prikazuje koliko često je svaka provera označila stručnjačko pitanje kao problematično. Niža vrednost je bolja, jer znači manje lažnih uzbuna.

Provera	Vrednost
Haladyna pravila (greška)	6,5
Rešivost	$p = 0,94$
Gramatička ujednačenost	4,7%
Uverljivost distraktora	3,92 od 5
Dvosmislenost	24,8%
Lanac provere	42,3%

Tabela 4. Udeo stručnjačkih pitanja koje je svaka provera označila.


Najbolje se pokazala provera rešivosti, koja je propustila gotovo sva stručnjačka pitanja, a uz to, na namerno pokvarenim pitanjima, kod kojih je tačan odgovor zamenjen netačnim, uspela da prepozna 98 procenata grešaka. To je znak dobro konfigurisane provere, jer propušta dobra pitanja i hvata loša. Provere zasnovane na pravilima, gramatici i uverljivosti takođe su dobro podešene. Sa druge strane, lanac provere je previše strog, jer je označio 35,6 procenta stručnjačkih pitanja, to pokazuje da je provera po prirodi stroga za pitanja koja se oslanjaju na predznanje. Provera dvosmislenosti je pokazala umerenu strogost, sa 24,8 procenata, pri čemu je pregled primera pokazao da se delom radi o stvarno kontekstualno zavisnim pitanjima, a delom o lažnim uzbunama.

4.6. Direktno poređenje kvaliteta naših i ekspertskih pitanja

Pored kalibracije, isti sloj provera omogućava i direktno poređenje. Za svaku meru koja postoji i za naša i za ekspertska pitanja možemo videti kako se naša generisana pitanja drže naspram pitanja koja su pisali stručnjaci. Sve mere su računane istim modelom (Claude Haiku 4.5) i, gde je to bitno, istim pristupom, jer lanac provere koristi širi kontekst na obe strane. Tabela 5 daje pregled po lekcijama i za ekspertska pitanja.

Mera	Procesi	Niti	Konkurentnost	Ekspertska
Rešivost (mean p)	0,90	0,95	0,91	0,94
Rešivost iz teksta	50%	69%	64,2%	45,3%
Lanac provere potvrđeno	54,4%	67,6%	64,2%	64,7%
Uverljivost distraktora	3,69	3,58	3,51	3,92
Dvosmislenost	4,4%	7,0%	3,2%	24,7%
Gramatički trag	3,3%	4,2%	6,3%	4,7%
Haladyna ocena	95,4	95,4	95,9	93,5
Čitljivost	19,1	16,4	21,3	10,3

Tabela 5. Direktno poređenje mera kvaliteta: naše tri lekcije i ekspertska EduQG pitanja.



Slika 11. Kvalitet naših pitanja (prosek tri lekcije) naspram ekspertskih, po metrici. Vrednosti su normalizovane tako da je kod svih mera viša vrednost bolja.

Po rešivosti su naša i ekspertska pitanja praktično izjednačena, sa prosečnim koeficijentom oko 0,9 na obe strane, što znači da su podjednako rešiva slepom solveru. Slično, po rešivosti iz samog teksta pitanja, koja proverava da li pitanje nosi glavnu misao i bez ponuđenih opcija, naša pitanja su čak nešto bolja, sa 50 do 69 procenata naspram 45,3 procenta kod ekspertskih, što je očekivano jer su ekspertska EduQG pitanja često kontekstualno zavisna, pa se ređe mogu rešiti bez gledanja u opcije. Po lancu provere naša pitanja su na nivou ekspertskih, a na lekcijama Niti i Konkurentnost čak i nešto iznad. Po gramatičkoj ujednačenosti i Haladyna pravilima razlike su zanemarljive, pri čemu su naša pitanja po Haladyna oceni neznatno bolja, što je očekivano jer su ta pravila ugrađena u sam prompt za generisanje.

Dve mere zaslužuju oprez. Prvo, po uverljivosti distraktora ekspertska pitanja su nešto bolja (3,92 naspram 3,5 do 3,7), što potvrđuje da su distraktori i dalje najteži deo i glavni prostor za napredak. Drugo, po dvosmislenosti naša pitanja deluju znatno bolja, sa svega nekoliko procenata naspram skoro 25 procenata kod ekspertskih, ali to ne treba čitati kao da su naša pitanja jasnija od stručnjačkih. Razlog je u tome što su EduQG pitanja na engleskom i često kontekstualno zavisna, pa ih naš detektor dvosmislenosti, podešen na drugačiji stil, češće označi. Slično, čitljivost se računa formulom vezanom za engleski

jezik, pa veći broj kod naših pitanja delom potiče od dužih srpskih reči, a ne nužno od teže formulacije.

Sveukupno, poređenje pokazuje da se naša automatski generisana pitanja drže vrlo dobro naspram pitanja koja su pisali stručnjaci. Na većini mera su izjednačena, na nekima i bolja, a jasno zaostaju jedino po uverljivosti distraktora. To je u skladu sa ranijom kvalitativnom analizom, koja je takođe pokazala da je generisanje distraktora najslabija tačka sistema.

4.7. Osvrt na rezultate i ograničenja

Rezultati daju odgovore na sva četiri istraživačka pitanja. Na prvo pitanje, o usklađenosti sa SOLO nivoom, odgovor je da je usklađenost sa globalnim modelom značajna, sa Koenovim koeficijentom od 0,68 do 0,78. Na drugo pitanje, o kvalitetu distraktora, odgovor je da su distraktori uverljivi po meri ocene, ali da je postojala mana parafraziranja tačnog odgovora, koja pokušavamo otkloniti. Na treće pitanje, o pokrivenosti, odgovor je da pitanja pokrivaju oko polovine do dve trećine pojmova po lekciji, što ostavlja prostora za više pitanja po pojmu. Na četvrto pitanje, o tačnosti i ispravnosti, odgovor je da je provera rešivosti vrlo pouzdana, dok je lanac provere strog, ali ga širi kontekst poboljšava.

Glavno ograničenje je veličina studije slučaja, koja obuhvata jedan kurs i tri lekcije, pa brojke daju jasan smer, ali ne i uske intervale poverenja. Drugo ograničenje je to što su rezultati za lokalni i globalni model snimljeni izvedeni na pitanjima koja su generisana i lokalno i globalno, bilo bi idelano da merimo lokalna pitanja i sa lokalnom i haiku evaluacijom i onda da merimo haiku pitanja sa lokalnom i haiku evaluacijom, ali iz finansijskih razloga API poziva su odrađene 2 kombinacije, sve lokalno i sve globalno, bez mešanja. Treće, spoljni skup EduQG je na engleskom jeziku i iz drugih oblasti, dok je studija slučaja na srpskom i iz oblasti operativnih sistema, pa brojke o generisanju treba čitati u tom svetlu. Uprkos tome, glavni nalaz je jasan i dosledan: sistem sa slojem za kontrolu kvaliteta i jačim modelom daje pitanja koja su merljivo bolja od polazne verzije.

5. Prototip softverske aplikacije

Sistem je dostupan kroz veb aplikaciju koja vodi nastavnika kroz ceo postupak, od unosa materijala do gotove provere. Korisnički deo je napravljen u tehnologiji React, a serverski u okviru Flask. Aplikacija je organizovana u nekoliko celina.

U celini za upravljanje kursevima i lekcijama nastavnik pravi kurs, dodaje lekcije i učitava materijale u PDF formatu. Nakon učitavanja, sistem raščlanjuje materijal i prikazuje izvučenu strukturu, odnosno sekcije i nastavne objekte, koje nastavnik može da pregleda i po potrebi ispravi. U celini za pregled sadržaja prikazuje se i ontologija, a moguće je postavljati i upite jezikom SPARQL nad izgrađenim grafom znanja.

U celini za generisanje pitanja nastavnik pokreće pravljenje pitanja po SOLO nivoima, a napravljena pitanja se skupljaju u banci pitanja, gde se mogu pregledati, izmeniti ili obrisati. Iz banke se zatim u celini za sastavljanje kviza bira koliko pitanja po kom nivou ulazi u proveru, a u celini za rešavanje kviza provera se može i odraditi.

Najvažniji deo za ovaj rad je kontrolna tabla kvaliteta, koja jednim klikom pokreće svih dvanaest provera nad pitanjima jedne lekcije i prikazuje rezultate u obliku kartica, sa ocenom koja odmah da li je mera dobra. Pošto neke provere traže mnogo poziva modela i mogu dugo da traju, rezultati se keširaju, pa se pri ponovnom otvaranju odmah prikazuju, bez ponovnog računanja. Dodata je i posebna stranica za poređenje sa referentnim skupom EduQG, koja prikazuje stručnjačka pitanja i pored svakog pokazuje kako je svaka provera prošla, čime se na istom mestu vidi kalibracija samih mernih instrumenata. Aplikacija podržava i prevođenje sadržaja, pa se pitanja mogu pripremiti na više jezika.

6. Zaključak

U ovom radu je predstavljen sistem za automatsko generisanje pitanja za proveru znanja po SOLO taksonomiji, koji spaja velike jezičke modele sa ontološkim opisom gradiva i sa slojem za kontrolu kvaliteta zasnovanim na pedagoškoj literaturi. Za razliku od početne verzije sistema, koja osim pilot studije nije imala evaluaciju, ovde je kvalitet izmeren brojkama, po lekcijama i zbirno, i to kroz dvanaest provera povezanih sa četiri istraživačka pitanja.

Glavni nalaz je da sloj za kontrolu kvaliteta u velikoj meri zavisi od sposobnosti modela da sudi, pa je prelazak sa lokalnog modela od 14 milijardi parametara na jači model u *cloud*-u doneo izrazito poboljšanje na svim merama koje traže zaključivanje, od slaganja sa SOLO nivo-om i indeksa podudaranja sa ciljem, preko lanca provere i rešivosti iz teksta, do smanjenja dvosmislenosti i bolje gramatičke ujednačenosti opcija. Pored toga, proverom na spoljnom referentnom skupu EduQG kalibrisani su sami merni instrumenti, pri čemu se provera rešivosti pokazala kao veoma pouzdana, davanjem šireg konteksta lancu provere, čime je udeo potvrđenih pitanja na jednoj lekciji porastao sa 38,9 na 54,4%, a otkrivena je i skrivena mana u generisanju distraktora, koju pokušavamo otkloniti.

Budući rad ima nekoliko pravaca. Prvi je veća studija evaluacije, sa više kurseva i lekcija, da bi se dobile uže ocene i intervali poverenja. Drugi je dalje podešavanje pojedinih provera, pre svega praga strogosti lanca provere i provere dvosmislenosti. Treći je proba sa drugim modelima i merenje odnosa brzine, cene i kvaliteta, jer je sa sve većim brojem provera vreme obrade osetno poraslo, pa se postavlja pitanje da li bi jači model u *cloud*-u dao i bolji kvalitet i kraće vreme. Četvrti je proširenje sistema izvan pitanja višestrukog izbora, ka pitanjima sa kratkim odgovorom i esejskim pitanjima.

Literatura

- [1] Chan, C.C., Tsui, M.S., Chan, M.Y. and Hong, J.H., 2002. Applying the structure of the observed learning outcomes (SOLO) taxonomy on student's learning outcomes: An empirical study. *Assessment & Evaluation in Higher Education*, 27(6), pp. 511-527.
- [2] Smith, B., 2012. Ontology. *The furniture of the world*, pp. 47-68.
- [3] Mitkov, R., 2003. Computer-aided generation of multiple-choice tests. In *Proceedings of the HLT-NAACL 03 workshop on Building educational applications using natural language processing* (pp. 17-22).
- [4] Kasneci, E. i dr., 2023. ChatGPT for good? On opportunities and challenges of large language models for education. *Learning and individual differences*, 103, p. 102274.
- [5] Lister, R., Simon, B., Thompson, E., Whalley, J.L. and Prasad, C., 2006. Not seeing the forest for the trees: novice programmers and the SOLO taxonomy. *ACM SIGCSE Bulletin*, 38(3), pp. 118-122.
- [6] Liang, C., Yang, X., Dave, N., Wham, D., Pursel, B. and Giles, C.L., 2018. Distractor generation for multiple choice questions using learning to rank. In *Proceedings of the thirteenth workshop on innovative use of NLP for building educational applications* (pp. 284-290).
- [7] Scaria, N., Dharani Chenna, S. and Subramani, D., 2024. Automated educational question generation at different Bloom's skill levels using large language models: Strategies and evaluation. In *International conference on artificial intelligence in education* (pp. 165-179). Springer.
- [8] Wei, J., Wang, X., Schuurmans, D., Bosma, M., Xia, F., Chi, E., Le, Q.V. and Zhou, D., 2022. Chain-of-thought prompting elicits reasoning in large language models. *Advances in neural information processing systems*, 35, pp. 24824-24837.
- [9] Sweller, J. and Cooper, G.A., 1985. The use of worked examples as a substitute for problem solving in learning algebra. *Cognition and instruction*, 2(1), pp. 59-89.
- [10] Lewis, P. i dr., 2020. Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in neural information processing systems*, 33, pp. 9459-9474.
- [11] Bitew, S.K., Deleu, J., Develder, C. and Demeester, T., 2023. Distractor generation for multiple-choice questions with predictive prompting and large language models. In

Joint European Conference on Machine Learning and Knowledge Discovery in Databases (pp. 48-63). Springer.

[12] Zhang, T., Kishore, V., Wu, F., Weinberger, K.Q. and Artzi, Y., 2019. BERTScore: Evaluating text generation with BERT. arXiv preprint arXiv:1904.09675.

[13] Considine, J., Botti, M. and Thomas, S., 2005. Design, format, validity and reliability of multiple choice questions for use in nursing research and education. *Collegian*, 12(1), pp. 19-24.

[14] Tarrant, M. and Ware, J., 2008. Impact of item-writing flaws in multiple-choice questions on student achievement in high-stakes nursing assessments. *Medical Education*, 42(2), pp. 198-206.

[15] Chen, C.H. and Shiu, M.F., 2025. KAQG: A knowledge-graph-enhanced RAG for difficulty-controlled question generation. *IEEE Access*, 13, pp. 197234-197244.

[16] Haladyna, T.M., Downing, S.M. and Rodriguez, M.C., 2002. A review of multiple-choice item-writing guidelines for classroom assessment. *Applied measurement in education*, 15(3), pp. 309-333.

[17] Dhuliawala, S. i dr., 2024. Chain-of-verification reduces hallucination in large language models. In *Findings of the Association for Computational Linguistics: ACL 2024* (pp. 3563-3578).

[18] Crocker, L. and Algina, J., 1986. *Introduction to classical and modern test theory*. Holt, Rinehart and Winston.

[19] Rovinelli, R.J. and Hambleton, R.K., 1977. On the use of content specialists in the assessment of criterion-referenced test item validity. *Dutch Journal of Educational Research*, 2, pp. 49-60.

[20] Landis, J.R. and Koch, G.G., 1977. The measurement of observer agreement for categorical data. *Biometrics*, 33(1), pp. 159-174.

[21] Cohen, J., 1960. A coefficient of agreement for nominal scales. *Educational and psychological measurement*, 20(1), pp. 37-46.

[22] Kurdi, G., Leo, J., Parsia, B., Sattler, U. and Al-Emari, S., 2020. A systematic review of automatic question generation for educational purposes. *International journal of artificial intelligence in education*, 30(1), pp. 121-204.

[23] Flesch, R., 1948. A new readability yardstick. *Journal of applied psychology*, 32(3), p. 221.

[24] Kincaid, J.P., Fishburne Jr, R.P., Rogers, R.L. and Chissom, B.S., 1975. Derivation of new readability formulas for navy enlisted personnel. *Research Branch Report 8-75*.

- [25] Downing, S.M., 2005. The effects of violating standard item writing principles on tests and students. *Advances in health sciences education*, 10(2), pp. 133-143.
- [26] Sadler, P.M., 1998. Psychometric models of student conceptions in science. *Journal of Research in Science Teaching*, 35(3), pp. 265-296.
- [27] Hadifar, A., Bitew, S.K., Deleu, J., Develder, C. and Demeester, T., 2023. EduQG: A multi-format multiple-choice dataset for the educational domain. *IEEE Access*, 11, pp. 20885-20896.